

AERODELAY: Thu thập Dữ liệu Hàng không và Tiền xử lý cho Bài toán Dự đoán Trễ chuyến bay chuyên tại Việt Nam giai đoạn từ 12/2025 đến 03/2026

Bạch Thanh Hương^{1,2}, Nguyễn Việt Hùng^{1,2}

¹University of Information Technology, Ho Chi Minh City, Vietnam

²Vietnam National University, Ho Chi Minh City, Vietnam
{24520636, 24520617}@gm.uit.edu.vn

Abstract—AeroDelay là đồ án tập trung xây dựng hệ thống thu thập, tiền xử lý và trích xuất đặc trưng cho bài toán phân tích và dự báo trễ chuyến bay chuyên tại ba cảng hàng không lớn tại Việt Nam: Tân Sơn Nhất (SGN), Nội Bài (HAN) và Đà Nẵng (DAD) trong giai đoạn từ 12/2025 đến 03/2026. Khác với các nghiên cứu truyền thống chú trọng tối ưu mô hình, nghiên cứu tập trung giải quyết các thách thức đặc thù của dữ liệu hàng không như bất đồng ngữ nghĩa thời gian, thiếu liên kết arrival-departure, và chuẩn hóa thông tin đường băng. Dữ liệu được tổ chức theo kiến trúc phân tầng Bronze-Silver-Gold, kết hợp dữ liệu chuyến bay từ FlightRadar24 và dữ liệu thời tiết từ Open-Meteo. Quy trình xử lý tạo ra bộ dữ liệu Gold gồm 77.758 bản ghi departure (với 72.375 chuyến bay chở khách làm tập huấn luyện chính) và 6.624 bản ghi thời tiết theo giờ. Kết quả thực nghiệm benchmark cho thấy bộ dữ liệu Gold chứa tín hiệu dự đoán rõ ràng: mô hình LightGBM kết hợp nhóm đặc trưng khí tượng hàng không đạt MAE 13.38 phút, cải thiện 26,1% so với Dummy Median baseline (18.10 phút). Bên cạnh pipeline được điều phối bằng Dagster, đồ án còn tích hợp LLM để tự động hóa việc gán nhãn nguyên nhân trễ theo chuẩn IATA và phát triển giao diện tương tác trên Streamlit. AeroDelay cung cấp một nền tảng dữ liệu hàng không chuẩn hóa, có audit đầy đủ, sẵn sàng làm cơ sở đáng tin cậy cho các nghiên cứu tiếp theo về tối ưu hóa vận hành cảng hàng không tại Việt Nam.

I. GIỚI THIỆU

Trễ chuyến bay là một hiện tượng vận hành mang tính dây chuyền điển hình trong ngành hàng không. Khi một chuyến bay đến muộn, thời gian xoay vòng tàu bay bị rút ngắn, dẫn đến hiệu ứng domino làm chậm trễ các chuyến bay tiếp theo và gia tăng áp lực lên hạ tầng sân bay, đặc biệt trong giờ cao điểm. Tại ba sân bay lớn nhất Việt Nam — Tân Sơn Nhất (SGN), Nội Bài (HAN) và Đà Nẵng (DAD) — dữ liệu chuyến bay thực tế tồn tại nhiều hạn chế nghiêm trọng: phân mảnh theo nguồn, khác biệt ngữ nghĩa thời gian, thiếu liên kết arrival-departure, trùng lặp bản ghi, thiếu thông tin đường băng và nguy cơ data leakage khi xây dựng đặc trưng. Những vấn đề này khiến việc phân tích và dự báo trễ chuyến bay gặp nhiều khó khăn.

Các nghiên cứu quốc tế về trễ chuyến bay chủ yếu tập trung vào phân tích nguyên nhân, dự báo bằng học máy kết hợp dữ liệu chuyến bay–thời tiết, và mô hình hóa sự lan truyền delay qua chuỗi xoay vòng tàu bay. Đáng chú ý, bộ dữ liệu Aeolus

của Xu et al. (2025) là một dataset đa cấu trúc quy mô lớn với hơn 50 triệu chuyến bay, cung cấp dữ liệu dạng bảng, chuỗi chuyến bay và đồ thị mạng bay nhằm hỗ trợ nghiên cứu delay propagation. Tương tự, Zhou et al. (2022) đề xuất mô hình hai giai đoạn (*two-stage model*) nhằm tách biệt dự báo delay ban đầu và mô hình hóa hiệu ứng lan truyền, đồng thời nhấn mạnh vai trò quan trọng của turnaround buffer, airport congestion và temporal features.

Hiện nay, vẫn tồn tại khoảng trống nghiên cứu rõ nét tại bối cảnh Việt Nam: thiếu bộ dữ liệu chuẩn hóa, ít công trình tập trung sâu vào chất lượng dữ liệu và kiểm soát leakage, cũng như chưa có pipeline toàn diện kết hợp thực thể arrival-departure, turnaround buffer, đặc trưng vận hành khí tượng và lớp diễn giải.

Đồ án AeroDelay được triển khai nhằm lấp đầy những khoảng trống trên thông qua việc xây dựng pipeline dữ liệu hoàn chỉnh theo kiến trúc Bronze–Silver–Gold. Ngoài pipeline cốt lõi, đồ án còn tích hợp LLM trong quá trình tiền xử lý để gán nhãn nguyên nhân trễ, Streamlit Dashboard cho giao diện tương tác trực quan hóa và Dagster pipeline để điều phối quy trình từ đầu đến cuối. Thông qua đó, AeroDelay không chỉ tạo ra bộ dữ liệu Gold chất lượng mà còn cung cấp một nền tảng minh bạch, có khả năng tái lập và dễ dàng mở rộng cho các nghiên cứu tiếp theo về trễ chuyến bay và vận hành hàng không tại Việt Nam.

II. PHƯƠNG PHÁP

A. Tổng quan bộ dữ liệu

Dữ liệu của AeroDelay được thu thập chủ yếu từ FlightRadar24, bao gồm dữ liệu chuyến bay trong lịch sử cho hai luồng arrival và departure tại hai sân bay lớn của Việt Nam: Tân Sơn Nhất (SGN) và Nội Bài (HAN). Riêng dữ liệu chuyến bay tại Đà Nẵng được bổ sung trực tiếp từ Cảng hàng không quốc tế Đà Nẵng.

Dữ liệu thời tiết được lấy từ Open-Meteo và được chuẩn hóa theo giờ để tích hợp với dữ liệu chuyến bay. Ngoài ra, đồ án sử dụng các tài liệu tham chiếu công khai về sân bay, đường băng, quy trình A-CDM và mã lý do trễ chuyến IATA để hỗ trợ xử lý nghiệp vụ và diễn giải nguyên nhân chậm trễ.

Pipeline AeroDelay được xây dựng theo kiến trúc phân tầng Bronze - Silver - Gold, nhằm tách biệt rõ ràng giữa dữ liệu thô, dữ liệu đã chuẩn hóa và dữ liệu sẵn sàng cho phân tích/mô hình hóa. Thiết kế này đảm bảo tính minh bạch, khả năng tái lập và dễ dàng truy vết thông qua hệ thống audit.

TABLE I
KIẾN TRÚC DỮ LIỆU CỦA HỆ THỐNG

Lớp	Vai trò chính	Dữ liệu chính
Bronze	Lưu trữ dữ liệu thô từ nguồn	Dữ liệu Arrival, Departure, Weather thô
Silver	Làm sạch, chuẩn hóa, xử lý trùng, missing và audit	Dữ liệu Arrival, Departure, Weather đã xử lý, Kết quả Audit
Gold	Dữ liệu sẵn sàng cho phân tích và mô hình	Master departure features, Annotated data
Audit	Theo dõi chất lượng dữ liệu và benchmark	Tổng quan Audit, Báo cáo Leakage, Kết quả Benchmark
Mở rộng	Điều phối pipeline và giao diện người dùng	Dagster pipeline, Streamlit app

Sau quá trình tiền xử lý, hệ thống tạo ra 151.929 bản ghi chuyến bay ở lớp Silver/Gold, bao gồm 77,758 bản ghi departure và 74,171 bản ghi arrival. Từ lớp Gold, đồ án xây dựng bảng đặc trưng departure gồm 77,758 bản ghi, trong đó 72.375 bản ghi chuyến bay chở khách được sử dụng cho tập huấn luyện và đánh giá mô hình. Bên cạnh đó, dữ liệu thời tiết được chuẩn hóa thành 6.624 bản ghi theo giờ để tích hợp với đặc trưng chuyến bay.

B. Quy trình thu thập dữ liệu

Dữ liệu của AeroDelay được thu thập thông qua hệ thống cào dữ liệu chuyên biệt, được thiết kế riêng theo từng sân bay và từng chiều bay tại ba cảng hàng không lớn: Tân Sơn Nhất (SGN), Nội Bài (HAN) và Đà Nẵng (DAD). Bộ dữ liệu bao gồm cả arrival và departure, với phạm vi thời gian chính từ ngày 15/12/2025 đến 16/03/2026.

Cụ thể:

Bộ dữ liệu tổng hợp chuyến bay Departure tại tầng Gold dùng cho trích xuất đặc trưng và benchmark mô hình có khoảng thời gian từ 15/12/2025 18:00 đến 16/03/2026 23:40.

Dữ liệu thời tiết theo giờ được thu thập từ 15/12/2025 00:00 đến 16/03/2026 23:00.

Quá trình thu thập phải đối mặt với nhiều thách thức đặc thù của dữ liệu hàng không thực tế như: hiệu suất chậm, cào dữ liệu qua nhiều trang, giao diện nguồn thay đổi thường xuyên, selector không ổn định, lịch bay được cập nhật liên tục, thiếu thông tin tail number, runway, category, sự chênh lệch giữa thời gian theo lịch và thời gian thực sự của chuyến, cũng như khó khăn trong việc liên kết arrival và departure.

Để xử lý hiệu quả, hệ thống crawler được chia thành nhiều script chuyên trách, mỗi script đảm nhận một nhiệm vụ cụ thể. Sau khi crawl, dữ liệu thô được lưu trữ nguyên vẹn tại lớp Bronze, phân theo sân bay, chiều bay và khí tượng. Các bước xử lý tiếp theo chỉ được thực hiện ở các lớp Silver và Gold. Cách tổ chức này giúp giữ lại dữ liệu nguyên vẹn với nguồn dữ

liệu gốc, đồng thời đảm bảo mọi thay đổi sau này đều có thể truy vết và tái lập đầy đủ trong pipeline Bronze-Silver-Gold.

TABLE II
CÁC THÀNH PHẦN THU THẬP DỮ LIỆU

Thành phần	Vai trò
crawl_arrival_history.py, crawl_departure_history.py	Thu thập dữ liệu chuyến bay arrival và departure trong lịch sử cho SGN và HAN.
crawl_dad_arrival.py, crawl_dad_departure.py	Thu thập dữ liệu chuyến bay arrival/departure cho sân bay Đà Nẵng.
crawl_dad_arrival_aircraft.py, crawl_dad_departure_aircraft.py	Bổ sung thông tin tàu bay cho dữ liệu chuyến arrival/departure của DAD.
crawl_dad_runway_category.py	Thu thập và bổ sung thông tin runway và category cho DAD.
crawl_latest_departure_data.py	Thu thập dữ liệu departure gần thời gian thực cho các ngày mới nhất.
crawl_missing_arrival_flights.py, crawl_missing_departure_flights.py	Bổ sung các chuyến bay bị thiếu sau khi audit liên kết thực thể arrival-departure.
weather_crawling.py	Thu thập dữ liệu thời tiết theo giờ từ Open-Meteo cho SGN, HAN và DAD.

Tựu chung lại từ các script, hệ thống crawler có 3 hướng cào dữ liệu chính: cào từ web FlightRadar24, cào từ web Cảng hàng không quốc tế Đà Nẵng, và cào từ OpenMeteo qua API.

FlightRadar24 có cơ chế bảo mật chống bot nghiêm ngặt nên quá trình thu thập được thực hiện bằng phương pháp web crawling sử dụng thư viện `undetected_chromedriver` (một biến thể của Selenium giúp vượt qua màn hình kiểm tra bot) kết hợp với BeautifulSoup và thư viện xử lý json. Đặc điểm nổi bật là hệ thống áp dụng hai phương pháp tiếp cận khác nhau trên cùng một trang đích để tối ưu hóa việc lấy dữ liệu cho Arrival và Departure. Quy trình thu thập gồm các bước chính sau:

- 1) Khởi tạo trình duyệt ẩn danh bằng `undetected_chromedriver` và chia nhỏ danh sách ngày tháng để chạy đa luồng.
- 2) Mở trang lịch sử chuyến bay của sân bay mục tiêu theo từng mốc thời gian.
- 3) **Đối với chiều Arrival:** Trình duyệt đợi bảng dữ liệu tải hoàn tất, sau đó sử dụng BeautifulSoup để phân tích trực tiếp cấu trúc cây DOM (HTML) và trích xuất từng hàng trong bảng.
- 4) **Đối với chiều Departure:** Không phân tích HTML thô mà tìm kiếm và trích xuất trực tiếp khối dữ liệu JSON dạng tổng thể được nhúng ngầm trong mã nguồn trang web chính và trang web thứ 2, giúp lấy dữ liệu nhanh và sâu hơn.
- 5) Làm sạch dữ liệu và trích xuất các trường thông tin cần thiết.
- 6) Ghi dữ liệu vào tệp CSV thông qua cơ chế khóa luồng (`threading.Lock()`).

Do dữ liệu chuyến bay nội bộ tại website Cảng Hàng không Đà Nẵng được hiển thị trên một giao diện web tiêu chuẩn, quá trình thu thập được thực hiện bằng Selenium và BeautifulSoup. Cả hai chiều Arrival và Departure đều **áp dụng chung một phương pháp cào dữ liệu HTML** do cấu

trúc trang web tương đồng. Quy trình thu thập gồm các bước chính sau:

- 1) Khởi tạo trình duyệt tự động và chia danh sách ngày cần thu thập để xử lý song song hai luồng.
- 2) Mở URL trang thông tin chuyến bay (đi hoặc đến) của sân bay Đà Nẵng.
- 3) Tương tác với giao diện trang (nếu cần) để hiển thị đầy đủ lịch bay của mốc ngày mục tiêu.
- 4) Lấy mã HTML của trang web sau khi dữ liệu đã được tải lên giao diện.
- 5) Sử dụng BeautifulSoup để duyệt qua cấu trúc bảng, bóc tách từng ô dữ liệu tương ứng với thông tin chuyến bay.
- 6) Lưu dữ liệu được trích xuất vào tệp CSV theo dạng nói tiếp.

Khác với các trang web hiển thị giao diện, Open-Meteo cung cấp nền tảng API mở. Do đó, quá trình thu thập không cần dùng đến Selenium mà sử dụng trực tiếp thư viện requests để gọi API và pandas để xử lý cấu trúc dữ liệu. Điểm đặc biệt của quy trình này là sự kết hợp dữ liệu từ hai bộ API khác nhau. Quy trình thực hiện gồm các bước sau:

- 1) Khai báo tọa độ địa lý của các sân bay (SGN, HAN, DAD) như Bảng III và mốc thời gian cần truy vấn.
- 2) Gửi truy vấn GET đến **Archive API** để lấy các thông số khí tượng cơ bản (nhiệt độ, lượng mưa, áp suất, tốc độ gió...).
- 3) Gửi truy vấn GET đến **Historical Forecast API** để lấy riêng tham số Visibility nhằm tối ưu hóa băng thông.
- 4) Chuyển đổi chuỗi dữ liệu JSON trả về từ hai API thành các bảng dữ liệu độc lập và đồng bộ hóa định dạng thời gian.
- 5) Thực hiện ghép nối hai bảng dữ liệu dựa trên khóa chính là mốc thời gian.
- 6) Gộp dữ liệu của tất cả các sân bay thành một tập dữ liệu duy nhất và lưu ra tệp CSV.

Để đảm bảo an toàn dữ liệu khi chạy đa luồng quy mô lớn, chương trình sử dụng cơ chế Thread Lock để ngăn hiện tượng ghi đè tệp CSV khi nhiều luồng hoàn thành cùng lúc. Hệ thống cũng có cơ chế bỏ qua các mốc thời gian bị lỗi và liên tục theo dõi tốc độ thu thập qua RPM Monitor.

TABLE III
CẤU HÌNH VỊ TRÍ THU THẬP DỮ LIỆU KHÍ TƯỢNG THEO SÂN BAY

Sân bay	Vĩ độ	Kinh độ
SGN	10.8188	106.6519
HAN	21.2212	105.8072
DAD	16.0439	108.1995

C. Tiền xử lý dữ liệu

1) Tiền xử lý dữ liệu chuyến bay:

a) *Chuẩn hóa định dạng thời gian:* Một trong những quyết định quan trọng nhất tại tầng Silver là chuẩn hóa ngữ nghĩa thời gian giữa các nguồn dữ liệu. Dữ liệu từ Đà Nẵng (DAD) có cấu trúc khác biệt so với SGN và HAN, đặc biệt ở cách diễn giải các trường **Scheduled_Time** và **Actual_Time**.

Pipeline đưa tất cả về mô hình thời gian thống nhất gồm các mốc chính:

- **Scheduled_Time / Scheduled_DateTime:** Thời gian theo lịch.
- **Actual_Time / Actual_DateTime:** Thời gian thực tế (dùng tính thời gian trễ).
- **Event_Time:** Mốc thời gian chuẩn dùng cho matching, deduplication và feature engineering.

Toàn bộ thời gian được chuẩn hóa về múi giờ UTC+7, đồng thời xử lý logic rollover cho các chuyến bay trễ qua ngày tiếp theo để tránh tính sai thời gian trễ.

b) *Chuẩn hóa schema và làm sạch dữ liệu:* Dữ liệu từ các sân bay được chuẩn hóa schema về cùng một tập cột chung. Các giá trị rỗng hoặc không hợp lệ như NA, N/A, null, unknown hoặc chuỗi trống được chuyển thành missing value thống nhất.

Các bước làm sạch cơ bản bao gồm:

- Chuẩn hóa mã IATA, runway, category, airline và terminal.
- Loại bỏ các dòng header bị crawl nhầm.
- Đảm bảo các cột bắt buộc luôn tồn tại để xử lý nhất quán ở các bước sau.

c) *Xử lý missing runway:* Runway là trường quan trọng, phản ánh mật độ khai thác thực tế, hướng gió, rủi ro vận hành và khả năng đổi đường băng của sân bay. Tuy nhiên, dữ liệu runway trong nguồn crawl thường có tỷ lệ thiếu hoặc không hợp lệ cao, đặc biệt đối với các chuyến bay đến (arrival) và tại sân bay Đà Nẵng (DAD).

Khác với các bộ dữ liệu tính thường giả định khuyết ngẫu nhiên hoàn toàn (MCAR - Missing Completely At Random) để áp dụng các kiểm định thống kê như Little's MCAR, những sự cố về tín hiệu của ADS-B trong hàng không mang đặc tính không gian - thời gian rõ rệt và thường thuộc cơ chế MNAR (Missing Not At Random) do những nguyên nhân về điểm mù sóng hoặc giới hạn radar tại từng sân bay cụ thể.

Dưới góc độ vận hành không lưu, đài kiểm soát không lưu luôn duy trì một cấu hình đường băng cố định trong nhiều giờ liên tục cho đến khi hướng gió thay đổi. Do đó, việc sử dụng các thuật toán điền khuyết dựa trên phân phối xác suất ngẫu nhiên hay giá trị yếu vị sẽ phá vỡ tính liên tục vật lý của hoạt động khai thác. Vì vậy, pipeline thực hiện xử lý missing runway theo nguyên tắc *khôi phục có kiểm soát nghiệp vụ trên nhiều phương pháp* thay vì phân phối xác suất ngẫu nhiên, bao gồm ba bước chính:

- 1) **Chuẩn hóa giá trị sai:** Các giá trị runway không đúng quy chuẩn và lệch ngày thực tế được chuyển thành missing value.
- 2) **Nearest-neighbor imputation:** Tìm runway hợp lệ gần nhất trong cửa sổ thời gian ± 30 phút với cùng sân bay và cùng chiều bay.
- 3) **Fallback theo mặc định ở bảng IV:** Nếu không tìm thấy runway phù hợp trong cửa sổ thời gian, pipeline sử dụng runway mặc định dựa trên cấu hình hạ tầng, điều kiện khí tượng tại thời điểm đó và hướng vận hành phổ biến của từng sân bay.

TABLE IV
CẤU HÌNH RUNWAY MẠC ĐỊNH THEO SÂN BAY

Sân bay	Cất cánh	Đổi chiều	Hạ cánh	Đổi chiều
SGN	25L	07R	25R	07L
HAN	11R	29L	11L	29R
DAD	35R	17L	35L	17R

Cách tiếp cận này tuân thủ chặt chẽ nghiệp vụ luân chuyển mặt đất của đài ATC, giúp phục hồi dữ liệu với độ tin cậy vận hành cao nhất mà không cần phụ thuộc vào các giả định kiểm định phân phối ngẫu nhiên.

Bảng V trình bày kết quả khôi phục thông tin runway tại tầng Silver.

TABLE V
KẾT QUẢ KHÔI PHỤC THÔNG TIN RUNWAY

Sân bay	Mode	Missing trước xử lý	Nearest window	Default orientation
SGN	departure	247	245	2
SGN	arrival	932	851	81
HAN	departure	329	327	2
HAN	arrival	2,263	2,165	98
DAD	departure	755	755	0
DAD	arrival	756	756	0

Để chứng minh tính tối ưu và kiểm soát sai số của phương pháp nội suy chuỗi thời gian kết hợp luật không lưu được đề xuất trong hệ thống AeroDelay, nghiên cứu thiết lập một thực nghiệm kiểm chứng. Từ tập dữ liệu Silver đã có đầy đủ thông tin, hệ thống che khuất ngẫu nhiên 10% trường *Runway* để giả lập trạng thái mất tín hiệu ADS-B.

Ba cấu hình điền khuyết được thực nghiệm song song bao gồm: (1) **Điền khuyết yếu vị**; (2) **Trượt thời gian cơ bản**; và (3) **Lân cận thời gian + Nội suy nghiệp vụ**.

Bên cạnh Tỷ lệ phân loại sai (*MR*), nghiên cứu bổ sung thêm chỉ số *F1-Score* (Macro-average) làm độ đo cốt lõi. Do cấu hình đường băng ngoài thực tế mất cân bằng nghiêm trọng, *F1-Score* sẽ đóng vai trò xác định những thuật toán gán nhãn mù quáng theo số đông. Kết quả thực nghiệm điền khuyết trung bình trên ba cảng hàng không trọng điểm được tổng hợp tại Bảng VI.

TABLE VI
AUDIT KẾT QUẢ ĐIỀN KHUYẾT ĐƯỜNG BĂNG

Sân bay	Điền khuyết yếu vị		Trượt thời gian		Nội suy nghiệp vụ	
	MR	F1-Score	MR	F1-Score	MR	F1-Score
SGN	1.63%	0.3306	0.57%	0.7838	0.55%	0.7923
HAN	3.28%	0.2458	4.05%	0.4383	3.82%	0.4509
DAD	2.96%	0.2462	1.10%	0.6359	0.80%	0.7476

Kết quả tại Bảng VI minh chứng rõ rệt giá trị của việc điền khuyết theo nghiệp vụ. Tại sân bay Đà Nẵng (DAD), phương pháp Lân cận thời gian + Nội suy nghiệp vụ giảm sai số MR xuống chỉ còn 0.80% và đẩy mức F1-Score lên 0.7476, vượt trội hoàn toàn so với mô hình trượt thời gian tĩnh (0.6359).

Đặc biệt tại sân bay Nội Bài (HAN), mặc dù Baseline Điền khuyết yếu vị có vẻ đạt sai số MR thấp hơn (3.28%), nhưng F1-Score thấp ở mức 0.2458, cho thấy mô hình này dự báo sai hoàn toàn toàn bộ các chuyến bay nằm trong cửa sổ đảo chiều đường băng. Trong khi đó, AeroDelay giải quyết triệt để điểm mù này với F1-Score đạt mức 0.4509.

Về mặt nghiệp vụ vận hành, phần lớn các giá trị bị thiếu được khôi phục hiệu quả thông qua cơ chế nội suy láng giềng gần nhất (*nearest-neighbor imputation*). Tuy nhiên, một đặc thù động cần lưu ý trong quản lý không lưu là sự kiện đổi chiều đường băng luôn làm thay đổi quy trình hoạt động hệ thống sân bay để sắp xếp, thiết lập lại luồng tàu bay trên không và sơ đồ đường lăn dưới mặt đất. Tàu bay luôn ưu tiên cất và hạ cánh ngược chiều gió để tối ưu lực nâng, nhưng phi hành đoàn có thể chấp nhận gió xuôi đến ngưỡng 15 knots nếu chiều dài đường băng khả dụng cho phép và máy tính điều khiển bay tính toán đảm bảo biên độ an toàn. Thêm vào đó, dù quy định giảm thiểu tiếng ồn đô thị sẽ ưu tiên cố định một đầu đường băng khai thác, đài kiểm soát không lưu và phi công bắt buộc phải thực hiện đảo chiều cấu hình ngay lập tức nếu vận tốc gió xuôi vượt ngưỡng an toàn hoặc bề mặt đường băng bị ướt do mưa lớn.

Vì lý do này, sau quá trình nội suy tự động, các bản ghi đã được thực hiện audit lại một cách nghiêm ngặt dựa trên quy trình nghiệp vụ để đảm bảo mọi biến động đều được ghi nhận chính xác. Qua kiểm tra chéo với quy định trên, không ghi nhận chuyến bay nào bị nội suy sai trong tập mẫu kiểm chứng. Kết quả thực nghiệm này khẳng định tính ổn định vững chắc và độ tin cậy cao của quy trình khôi phục cấu hình đường băng mà AeroDelay đề xuất, đồng thời giúp hạn chế tối đa việc loại bỏ nhầm dữ liệu trong các bước xử lý đặc trưng tiếp theo.

d) *Xử lý trùng lặp*: Quá trình deduplication không chỉ dựa trên việc loại bỏ các dòng dữ liệu giống nhau tuyệt đối. Bởi trong dữ liệu chuyển bay, cùng một *Flight_No* có thể xuất hiện nhiều lần hợp lệ trong cùng một ngày hoặc trong các rotation khác nhau. Vì vậy, pipeline chỉ loại bỏ bản ghi khi có đủ bằng chứng nghiệp vụ cho thấy chúng thực sự là duplicate.

Quy tắc chính hiện tại là gom cụm các bản ghi có cùng service date, flight number, route/IATA và sân bay, sau đó loại bỏ các bản ghi nằm quá gần nhau trong một cửa sổ thời gian deduplication đã được xác định trước.

Kết quả audit cho thấy tổng cộng 71 bản ghi duplicate đã được loại bỏ, như trình bày trong Bảng VII.

TABLE VII
KẾT QUẢ LOẠI BỎ BẢN GHI TRÙNG LẶP

Sân bay	Mode	Số bản ghi loại bỏ
SGN	departure	54
SGN	arrival	1
HAN	departure	1
HAN	arrival	5
DAD	departure	8
DAD	arrival	2
Tổng cộng		71

Các bản ghi có cùng *Flight_No* nhưng cách xa nhau về

mặt thời gian vẫn được giữ lại, vì chúng có thể tương ứng với các chuyến bay hoặc rotation hợp lệ trong cùng ngày khai thác (chuyến bay trễ sang ngày hôm sau và chuyến thường lệ của ngày đó, ...). Cách tiếp cận này giúp giảm nguy cơ loại bỏ nhầm dữ liệu hợp lệ, đồng thời đảm bảo chất lượng dữ liệu đầu vào và huấn luyện mô hình ở các tầng xử lý tiếp theo.

e) *Liên kết arrival-departure*: Việc ghép nối chuyến bay arrival và departure được thực hiện như một bài toán *Entity Resolution*. Pipeline sử dụng ghép nối đa thuộc tính thay vì chỉ dựa vào *Flight_No*, nhằm tăng độ chính xác và giảm lỗi ghép nhầm.

Các thuộc tính ghép nối chính được trình bày trong Bảng VIII.

TABLE VIII
CÁC THUỘC TÍNH DÙNG CHO GHEP NOI ARRIVAL-DEPARTURE

Thuộc tính	Vai trò
Flight_No	Nhận diện số hiệu chuyến bay.
IATA / Route	Xác định quan hệ origin-destination.
Sân bay + Ngày bay	Phân biệt ngữ cảnh và tránh trùng ngày.
Event_Time	Tránh ghép nhầm khung giờ.
Tail_Number	Liên kết chuỗi khai thác tàu bay.

Sau matching ban đầu, những chuyến bay vẫn còn missing arrival hoặc departure được bổ sung thêm dữ liệu thông qua các script crawl chuyên biệt `crawl_missing_arrival_flights.py` và `crawl_missing_departure_flights.py`.

Các bản ghi chưa ghép được, hay còn gọi là missing link, không bị xóa tại tầng Silver mà được gắn cờ để đảm bảo tính minh bạch. Kết quả tại tầng Silver được trình bày trong Bảng IX.

TABLE IX
KẾT QUẢ MISSING LINK TẠI TẦNG SILVER

Loại missing link	Số bản ghi	Cách xử lý
Có chiều Arrival nhưng thiếu chiều departure	476	Gắn cờ <code>arrival_without_departure</code>
Có chiều Departure nhưng thiếu chiều arrival	619	Gắn cờ <code>dep_without_arrival</code>

f) *Phát hiện chuyến bay quay đầu khẩn cấp*: Trong dữ liệu arrival, một số bản ghi có đặc điểm bất thường là *Origin* trùng với sân bay đến (*same-origin*). Nếu xử lý đơn giản, các bản ghi này dễ bị coi là lỗi dữ liệu và bị loại bỏ. Tuy nhiên, trong thực tế vận hành hàng không, một phần trong số đó là các chuyến bay quay đầu (*return flight*) hoặc quay đầu khẩn cấp (*emergency return*) do sự cố kỹ thuật, thời tiết, y tế hoặc các nguyên nhân khác. Các chuyến này buộc sân bay phải ưu tiên chiếm dụng các đường băng cất cánh thay vì hạ cánh và dịch vụ mặt đất để thoát nhanh, thậm chí phong tỏa đường băng và ép sân bay phải đổi chiều runway. Việc phát hiện các chuyến này tránh gây sai lệch cho mô hình vì chúng gây xáo trộn dây chuyền và trì hoãn các chuyến bay kế tiếp.

AeroDelay không áp dụng quy tắc loại bỏ cứng mà thực hiện bước nhận diện riêng nhằm phân biệt giữa các trường hợp

hợp lệ và bất thường, giúp tránh sai sót dẫn đến ảnh hưởng các thông số mật độ sân bay. Các tiêu chí nhận diện được trình bày trong Bảng X.

TABLE X
TIÊU CHÍ NHẬN DIỆN SAME-ORIGIN VÀ RETURN FLIGHT

Tiêu chí	Vai trò
Origin trùng sân bay arrival Flight_No	Phát hiện các ứng viên same-origin hoặc return flight. Kiểm tra khả năng khớp với chuyến departure tương ứng.
Thời gian arrival/departure Category	Đánh giá khoảng thời gian quay đầu có hợp lý hay không. Ưu tiên giữ lại các chuyến non-commercial (helicopter, business jet, military, ...).
Runway và airport context	Hỗ trợ nhận diện các tình huống emergency theo logic vận hành.

Kết quả xử lý được ghi nhận trong file audit `audit_same_origin_actions.csv`. Các bản ghi same-origin được phân thành ba nhóm: chuyến bay return/emergency được giữ lại, chuyến bay non-commercial được giữ lại và các bản ghi bị loại bỏ.

TABLE XI
KẾT QUẢ XỬ LÝ SAME-ORIGIN

Sân bay	Same-origin rows	Return/ Emergency	Non-commercial	Bị loại
SGN	60	25	14	21
HAN	24	5	2	17
DAD	0	0	0	0
Tổng	84	30	16	38

Đối với các chuyến bay được xác định là return hoặc emergency, pipeline gắn cờ `Is_Return_Emergency = 1` và thực hiện remap runway theo logic sử dụng đường băng cất cánh thông thường thay cho đường băng hạ cánh. Audit ghi nhận tổng cộng 25 bản ghi được remap runway, bao gồm 20 bản ghi tại SGN và 5 bản ghi tại HAN.

Cách tiếp cận này giúp giảm thiểu hai rủi ro phổ biến trong xử lý dữ liệu hàng không: (i) loại bỏ nhầm các chuyến bay return/emergency hợp lệ và (ii) giữ lại các bản ghi same-origin thực chất là nhiễu dữ liệu. Nhờ đó, tầng Silver vừa bảo toàn được các tình huống vận hành đặc biệt, vừa duy trì chất lượng dữ liệu cho quá trình xây dựng các đặc trưng liên quan đến delay propagation và mật độ sân bay ở các tầng xử lý tiếp theo.

2) *Tiền xử lý dữ liệu thời tiết*: Làm sạch và chuẩn hóa dữ liệu thời tiết

Dữ liệu thời tiết thô ở tầng Bronze được lấy từ file `airport_weather_hourly_merged.csv`. Pipeline chuẩn hóa mã sân bay về IATA (SGN, HAN, DAD), ép kiểu numeric cho các biến chính và thực hiện kiểm tra missing/outlier.

Các bước xử lý chính được trình bày trong Bảng XII.

TABLE XII
CÁC BƯỚC TIỀN XỬ LÝ DỮ LIỆU THỜI TIẾT

Nhóm xử lý	Cách thực hiện
Kiểm tra giới hạn vật lý	Rút ngắn giá trị về khoảng hợp lý; Ví dụ: humidity 0–100%, wind direction 0–360°, pressure 850–1100 hPa.
Xử lý missing	Nội suy tuyến tính theo sân bay, sau đó fallback bằng median theo sân bay.
Kiểm soát outlier	Không áp dụng xử lý giá trị ngoại lệ cho các biến như precipitation, wind speed, visibility, CAPE và lifted index, vì các giá trị cực trị thường mang ý nghĩa vận hành.
Audit	Ghi nhận missing value, outlier và các hành động xử lý tương ứng.

Pipeline ưu tiên giữ lại các giá trị cực trị vì chúng có thể là nguyên nhân trực tiếp gây delay và ảnh hưởng đến hoạt động runway.

D. Phân tích khám phá và trích xuất đặc trưng thời tiết

Sau khi tiền xử lý, dữ liệu thời tiết trong AeroDelay được xử lý theo hướng *domain-driven feature engineering*. Thay vì sử dụng trực tiếp các biến khí tượng thô cho EDA và mô hình, pipeline chuyển đổi chúng thành các đặc trưng có ý nghĩa vận hành hàng không. Cách tiếp cận này phù hợp với bài toán trễ chuyển vì tác động của thời tiết đến chuyển bay thường không nằm ở giá trị thô riêng lẻ, mà nằm ở mối quan hệ giữa điều kiện khí tượng, hướng runway và các ngưỡng khai thác thực tế.

Ví dụ, $wind_speed = 20\text{ km/h}$ chưa cho biết gió đó hỗ trợ hay cản trở máy bay nếu không xét hướng gió so với hướng runway. Tương tự, $visibility = 4800\text{ m}$ cần được quy đổi và so sánh với các ngưỡng hàng không như 3SM hoặc 1SM; $precipitation > 0$ chưa đủ để kết luận runway có rủi ro ướt hay không. Vì vậy, pipeline xây dựng các feature thời tiết trước, sau đó EDA được thực hiện trên các biến đã có ngữ nghĩa mang tính vận hành.

Các nhóm đặc trưng chính bao gồm:

- **Thành phần gió theo runway:** Sử dụng hướng đường băng mặc định ($SGN: 250^\circ$, $HAN: 110^\circ$, $DAD: 350^\circ$) để tính headwind, crosswind, tailwind, góc tương đối giữa hướng gió và runway, cùng các cờ rủi ro crosswind/tailwind. Nhóm feature này quan trọng vì cùng một tốc độ gió có thể tạo tác động hoàn toàn khác nhau tùy hướng đường băng.
- **Visibility và fog risk:** Chuyển đổi tầm nhìn sang đơn vị miles và tạo các ngưỡng hàng không như dưới 3SM hoặc dưới 1SM. Fog risk được tính kết hợp giữa visibility, humidity, dew point spread, wind speed và khung giờ, giúp phân biệt sương mù thực sự với các trường hợp tầm nhìn giảm thông thường. Xác định chính xác đặc trưng về tầm nhìn và sương mù giúp đánh giá chính xác khả năng cất/hạ cánh thực tế tại sân bay.
- **Mưa và điều kiện runway:** Dù máy bay hiện đại có thể hoạt động trong điều kiện mưa, các yếu tố này vẫn tạo ra những rủi ro nhất định cho quá trình cất/hạ cánh. Vì vậy, các cờ xác định thời tiết mưa, lượng mưa tích lũy trong 1 giờ, 3 giờ và 6 giờ, đặc biệt là *Runway_Wet_Risk*, biến

phản ánh rủi ro tích lũy của mưa lên bề mặt đường băng, được trích xuất giúp hỗ trợ phản ánh các tác động rủi ro thực tế đến an toàn bay.

- **Low ceiling và convection risk:** Xây dựng các cờ rủi ro trần mây thấp, đối lưu mạnh, rủi ro về bão và điểm mức độ đối lưu dựa trên cloud cover low, CAPE và lifted index. Trong thực tế, trần mây thấp ($< 60m - 100m$) và đối lưu (CAPE cao) tạo ra điều kiện bay cực đoan, thường đi kèm mưa dông dải hẹp, gió giật cực kỳ nguy hiểm cho hoạt động bay. Khi không khí lạnh tương tác với độ ẩm cao, trần mây có thể giảm xuống dưới $60m$, làm giảm tầm nhìn ngang xuống dưới $400m$.
- **Forced runway swap risk:** Tạo proxy *Forced_Runway_Swap_Risk* để biểu diễn áp lực đổi hướng runway khi tailwind mạnh kết hợp với runway ướt. Áp lực này vẫn được xác định dựa trên các logic toán học và nghiệp vụ hàng không AIP.
- **Risk scores tổng hợp:** Xây dựng điểm rủi ro về thời tiết *Weather_Delay_Risk_Score* tổng hợp từ nhiều dữ liệu về khí tượng và điểm rủi ro về vận hành *Aviation_Operational_Risk_Score* tổng hợp từ nhiều dữ liệu về vận hành.

a) *Lý do xây dựng weather feature trước khi EDA:* Đặc trưng khí tượng được xây dựng trước EDA vì dữ liệu thô khó diễn giải trực tiếp trong bối cảnh hàng không. Ví dụ, wind speed cao chưa chắc đã nguy hiểm nếu gió thuộc loại headwind; visibility thấp cần được so sánh với ngưỡng 3SM hoặc 1SM; precipitation lớn hơn 0 chưa phản ánh runway wet risk cao nếu chỉ là mưa nhẹ.

Việc áp dụng quy tắc nghiệp vụ trong bối cảnh hàng không như quy tắc được quy định trong các tài liệu về ATC, AIP và vận hành runway để chuyển đổi biến thô thành các đặc trưng có ngữ nghĩa vận hành giúp EDA trả lời đúng các câu hỏi sát bài toán: crosswind có vượt ngưỡng hay không, tailwind có tạo áp lực đổi runway hay không, mưa có gây wet runway hay không, và fog với low ceiling có xuất hiện đồng thời hay không. Cách tiếp cận này làm cho EDA trở nên ý nghĩa và gắn kết chặt chẽ với bài toán dự báo trễ chuyển.

b) *Insight từ EDA thời tiết:* EDA cho thấy dữ liệu thời tiết tại ba sân bay có tính mất cân bằng mạnh. Phần lớn các giờ quan sát có *Weather_Delay_Risk_Score* bằng 0; chỉ khoảng 15.35% số giờ có risk lớn hơn 0 và chỉ 0.29% số giờ có risk lớn hơn hoặc bằng 2 (Fig. 1). Điều này cho thấy các điều kiện thời tiết bất lợi nghiêm trọng là những sự kiện tương đối hiếm trong phạm vi khoảng thời gian mà dữ liệu được thu thập. Tuy nhiên, đây lại là các tín hiệu có giá trị vận hành cao đối với bài toán trễ chuyển, do đó pipeline chủ động giữ lại các giá trị cực trị thay vì loại bỏ theo quy tắc xử lý outlier thông thường.




Fig. 1. Phân bố Weather Delay Risk Score.

Phân tích theo sân bay cho thấy sự khác biệt đáng kể về đặc điểm thời tiết. DAD có tỷ lệ mưa và rủi ro giông bão cao nhất, đặc biệt trong tháng 12 và đầu tháng 3. Điều này phù hợp với thực tế khí hậu miền Trung trong giai đoạn cuối năm và đầu năm, khi khu vực Đà Nẵng thường chịu ảnh hưởng của gió mùa đông bắc và các đợt mưa lớn cục bộ. HAN nổi bật với giá trị gió crosswind cực đại, phản ánh đặc điểm gió mùa mạnh hơn ở miền Bắc trong mùa đông. Trong khi SGN có tỷ lệ mưa thấp nhất trong ba sân bay trong khoảng thời gian quan sát, nhưng vẫn xuất hiện một số sự kiện mưa lớn cục bộ (tiêu biểu ngày 25/12), đúng với thực tế SGN thường xuyên có những những ngày có sự kiện khí tượng cực đoan bất chợt. So sánh hồ sơ rủi ro thời tiết giữa ba sân bay thể hiện trong Fig. 2.

Kết quả EDA cũng cho thấy các biến thời tiết chỉ thực sự có ý nghĩa khi được diễn giải trong bối cảnh vận hành hàng không. Gió cần được chuyển đổi thành các thành phần *Headwind*, *Crosswind* và *Tailwind* theo hướng runway; lượng mưa cần được đánh giá thông qua *Runway_Wet_Risk*; trong khi visibility thấp cần kết hợp với các yếu tố fog và low ceiling để phản ánh chính xác rủi ro khai thác. Phân tích tương quan cho thấy *Precip_Cumsum_3H_Mm* là biến có mối liên hệ mạnh nhất với *Weather_Delay_Risk_Score*, cho thấy lượng mưa tích lũy qua một khoảng thời gian mang nhiều thông tin hơn tổng số lượng mưa có tính tức thời. Ngoài ra, *Headwind_Kmh* thể hiện tín hiệu rõ ràng hơn *Crosswind_Kmh* trong bộ dữ liệu hiện tại, một hiện tượng cần được nghiên cứu sâu hơn theo từng sân bay và ngưỡng vận hành cụ thể tuy vẫn hợp lý về khoa học hàng không khi các máy bay thường phải cất/hạ cánh ngược chiều gió.




Fig. 3. Xếp hạng các đặc trưng khí tượng theo mức độ rủi ro.

Về chất lượng đặc trưng, audit cho thấy một số biến như *Is_Gale_Wind*, *Is_Freezing* và *Runway_Ice_Risk* có zero variance (luôn bằng 0) và được loại khỏi tập feature sử dụng cho mô hình. Biến *Is_Fog* xuất hiện với tần suất rất thấp mặc dù tồn tại một số khoảng thời gian có visibility thấp, cho thấy cần tiếp tục rà soát và tinh chỉnh logic nhận diện fog trong các phiên bản tiếp theo.

Nhìn chung, EDA thời tiết củng cố tính đúng đắn của cách tiếp cận *domain-driven feature engineering*. Các đặc trưng được xây dựng không nhằm mô tả khí tượng thuần túy mà tập trung biểu diễn tác động tiềm năng của thời tiết lên trễ dây chuyền và năng lực khai thác sân bay. Kết quả phân tích cũng cho thấy các đặc trưng dạng tích lũy, đặc biệt là lượng mưa tích lũy, mang lại tín hiệu mạnh hơn các biến thời tiết có giá trị tức thời và hỗ trợ hiệu quả cho quá trình kết hợp với dữ liệu chuyến bay tại tầng Gold.

E. Phân tích khám phá và trích xuất đặc trưng chuyến bay

Đối với dữ liệu chuyến bay, AeroDelay thực hiện Exploratory Data Analysis (EDA) sau khi dữ liệu đã được chuẩn hóa ở tầng Silver và tổng hợp lên tầng Gold. Khác với dữ liệu thời tiết, dữ liệu chuyến bay đã chứa nhiều trường mang ý nghĩa nghiệp vụ trực tiếp như *Scheduled_Time*, *Actual_Time*, *Tail_Number*, *Flight_No*, *Route* và *Runway*. Do đó, EDA ở phần này vừa đóng vai trò kiểm chứng cấu trúc dữ liệu, vừa là bước nền tảng để xây dựng feature engineering.

Mục tiêu chính là trả lời các câu hỏi cốt lõi của bài toán dự đoán trễ dây chuyền: phân bố trễ ra sao, mức độ tải sân bay và chuỗi xoay vòng tàu bay có ảnh hưởng đến trễ chuyển không, và turnaround buffer đóng vai trò gì trong việc hấp thụ hoặc lan truyền trễ chuyển.

Sau tiền xử lý, tầng Silver chứa 151 929 bản ghi arrival/departure từ ba sân bay SGN, HAN và DAD. Tầng Gold tạo ra 148 519 bản ghi có feature, trong đó bộ dữ liệu departure dùng cho mô hình gồm 77 758 bản ghi. Sau khi lọc chỉ giữ




Fig. 2. So sánh các nhóm rủi ro thời tiết giữa ba sân bay

các chuyến bay chở khách, tập dữ liệu cuối cùng còn 72 375 bản ghi. Phạm vi dữ liệu kéo dài từ ngày 15/12/2025 đến ngày 16/03/2026, bao quát giai đoạn cao điểm cuối năm và Tết Nguyên đán.

a) *Phân bố trễ và xây dựng biến mục tiêu*: Phân bố trễ của các chuyến bay departure có dạng lệch phải rõ rệt với đuôi dài, thể hiện trong Fig. 4. Median delay khoảng 23 phút, p95 đạt khoảng 113 phút, và một số outlier có thể lên đến nhiều giờ. Đây là đặc trưng điển hình của vận hành hàng không, nơi mà trễ chuyến thường bị ảnh hưởng bởi hiệu ứng dây chuyền, tắc nghẽn hạ tầng và các sự cố bất ngờ.

Từ insight này, pipeline xây dựng hai biến mục tiêu:

- *Departure_Delay*: thời gian trễ thực tế, tính theo phút.
- *Departure_Delay_Reg_Target*: target hồi quy sau khi cắt khoảng trễ âm về -60 và giới hạn outlier ở mức tối đa 720 phút.




Fig. 4. Phân phối trễ chuyến bay Departure

b) *Cấu trúc khai thác theo sân bay và loại chuyến bay*: Chuyến bay thương mại chở khách chiếm tỷ trọng áp đảo:

96.5% tại SGN, 90.7% tại HAN và 93.8% tại DAD. Do đó, benchmark mô hình được giới hạn trên tập dữ liệu chỉ có các chuyến trên để giảm nhiễu từ các loại hình chuyến bay khác như cargo, military và general aviation.

SGN là sân bay có mật độ khai thác cao nhất, tiếp theo là HAN và DAD. Về mạng đường bay, tuyến SGN–HAN lớn nhất với 6 676 bản ghi, tiếp theo là SGN–DAD với 3 195 bản ghi. Điều này phản ánh vai trò xương sống của tam giác SGN–HAN–DAD trong mạng bay Việt Nam. Sự áp đảo về số lượng bản ghi trên hai tuyến bay xuất phát từ Tân Sơn Nhất không chỉ minh chứng cho vị thế đầu tàu kinh tế và trung tâm trung chuyển hàng không lớn nhất cả nước của sân bay SGN, mà dưới góc nhìn dữ liệu, nó còn báo hiệu một áp lực vận hành khổng lồ lên hạ tầng sân bay này. HAN và DAD là cửa ngõ quốc tế lớn tại miền Bắc và miền Trung, đóng vai trò là hai trực tiếp nhận thứ cấp lớn nhất lượng hành khách khắp Việt Nam và chịu áp lực hấp thụ trực tiếp các đợt hoãn chuyến lan truyền.

Từ các insight này, pipeline tạo các đặc trưng như *Category*, *Airline_Type*, *Aircraft_Type*, *Is_Wide_Body*, *Origin*, *Destination*, *Destination_Congestion_Risk* và *Previous_Station_Disruption*.

c) *Lưu lượng theo thời gian và giờ cao điểm*: Lưu lượng chuyến bay không phân bố đều mà tập trung mạnh vào các khung giờ sáng, trưa và chiều tối (Fig. 5). Insight này cho thấy delay không chỉ phụ thuộc vào từng chuyến bay riêng lẻ mà còn phụ thuộc vào trạng thái hệ thống tại thời điểm vận hành.

Pipeline tạo nhóm đặc trưng thời gian như *Scheduled_Hour*, *Scheduled_DayOfWeek*, *Scheduled_Month*, *Is_Weekend*, *Time_of_Day*, *Peak_Hour_Indicator* và *Is_Special_Days*.




Fig. 5. Heatmap mật độ khai thác chuyển bay theo giờ và sân bay.

d) *Tải sân bay và tắc nghẽn*: Tải sân bay là nhóm tín hiệu mạnh nhất đối với departure delay (Fig. 6). Các feature có tương quan Spearman cao gồm:

- *Number_of_Flights_in_Last_Hour*: $\rho \approx 0.443$
- *Airport_Load_Factor*: $\rho \approx 0.362$
- *Ground_Handling_Pressure*, *Is_Airport_Congested* và *Taxi_Out_Congestion*.

Các đặc trưng này được tính theo dữ liệu thời gian dự kiến để tránh data leakage.




Fig. 6. Mối quan hệ giữa tải sân bay và departure delay.

e) *Trễ dây chuyền theo tàu bay*: EDA xác nhận rõ tính dây chuyền của trễ chuyển theo tàu bay. Hai đặc trưng có tín hiệu mạnh gồm:

- *Rolling_Departure_Delay_Tail_3*: $\rho \approx 0.340$
- *Prev_Departure_Delay_Tail_1*: $\rho \approx 0.325$

Từ insight này, pipeline thực hiện xây dựng nhóm đặc trưng như *Prev_Departure_Delay_Tail_1/2*, *Rolling_Departure_Delay_Tail_3*, *Prev_Turnaround_Buffer_Tail_1/2* và *Rolling_Turnaround_Buffer_Tail_3*. Tất cả lag features trên chỉ sử dụng dữ liệu đã xảy ra thực tế trước *Scheduled_Time* của chuyển hiện tại.

f) *Turnaround buffer và chuyển đầu ngày*: Turnaround buffer đóng vai trò quan trọng trong việc hấp thụ trễ. Các đặc trưng *Scheduled_Turnaround_Deficit* và *A_CDM_TOBT_Deficit* có tương quan dương khoảng $\rho \approx 0.196$ với departure delay, trong khi *Turnaround_Buffer_Model* có tương quan âm khoảng $\rho \approx -0.105$.

Ngoài ra, chuyển bay đầu ngày (*Is_First_Flight=True*) có median delay thấp hơn rõ rệt, khoảng 18 phút so với 28 phút ở các chuyển bay còn lại. Các

đặc trưng được xây dựng gồm *Standard_Turnaround*, *Turnaround_Buffer_Model*, *Scheduled_Turnaround_Deficit*, *Scheduled_Turnaround_Slack*, *Is_Long_Ground_Turnaround*, *Is_First_Flight* và *Tail_Sequence_Day*.

g) *Runway*: Phân tích runway cho thấy sự tập trung cao theo sân bay và chiều bay, hỗ trợ audit chất lượng dữ liệu và phát hiện runway swap. Pipeline tạo các cờ vận hành như *Runway_Swap_Event*, *Is_Parallel_Usage* và *Forced_Runway_Swap_Risk*

Tổng thể, quá trình EDA và feature engineering cho dữ liệu chuyển bay được thực hiện theo hướng tiếp cận qua nghiệp vụ, giúp tái tạo chính xác cơ chế trễ dây chuyền và đảm bảo tính khả dụng cho benchmark mô hình.

III. TẬP DỮ LIỆU TẦNG GOLD

Sau khi hoàn tất tiền xử lý, EDA và feature engineering, AeroDelay xây dựng tầng Gold nhằm tạo ra bộ dữ liệu cuối cùng, sẵn sàng phục vụ phân tích và benchmark mô hình. Khác với tầng Silver tập trung vào chuẩn hóa và audit chất lượng dữ liệu, tầng Gold được thiết kế theo hướng *model-ready*: schema ổn định, đặc trưng có ý nghĩa nghiệp vụ, mục tiêu rõ ràng và đã kiểm soát nghiêm ngặt rủi ro data leakage.

A. Đơn vị quan sát và cách xây dựng

Đơn vị quan sát chính trong bộ dữ liệu tầng Gold là một chuyển bay departure tại ba sân bay *SGN*, *HAN* và *DAD*. Việc chọn departure làm trung tâm là do bài toán tập trung dự báo và phân tích trễ chuyển bay departure, đồng thời dễ dàng gắn các đặc trưng về turnaround, arrival trước đó, tải sân bay, thời tiết và network disruption.

Gold dataset được xây dựng bằng cách tổng hợp:

- Dữ liệu chuyển bay từ tầng Silver.
- Kết quả ghép nối arrival-departure.
- Các đặc trưng vận hành như turnaround, lag delay và congestion.
- Dữ liệu thời tiết theo giờ.

B. Quy mô dữ liệu tầng Gold

Sau khi pipeline chạy hoàn chỉnh, Gold layer tạo ra:

- 148 519 bản ghi flight feature tổng hợp.
- 77 758 bản ghi departure, dùng cho modeling.
- 72 375 bản ghi chuyển bay thương mại chở khách, dùng làm tập huấn luyện và đánh giá chính.

Phạm vi thời gian của dữ liệu kéo dài từ 15/12/2025 18:00 đến 16/03/2026 23:40, bao quát giai đoạn cao điểm cuối năm và Tết Nguyên đán.

C. Biến mục tiêu

Mục tiêu chính cho bài toán hồi quy là *Departure_Delay_Reg_Target*, được tính từ delay thực tế giữa thời gian khởi hành thực tế và thời gian khởi hành theo lịch:

$$Departure_Delay = Actual_Time - Scheduled_Time$$

Để giảm ảnh hưởng của outlier cực đoan, target được rút ngắn trong khoảng $[-60, 720]$ phút. Thống kê trên tập chuyển bay thương mại chở khách cho thấy mean delay đạt 34.15 phút, median đạt 23 phút và p95 đạt 113 phút.

D. Phân tích cấu trúc tự tương quan chuỗi thời gian

Để làm rõ bản chất động lực học và tính chu kỳ dài hạn của hiện tượng trễ chuyển dây chuyền trong mạng lưới hàng không Việt Nam, nghiên cứu tiến hành khai thác cấu trúc hàm tự tương quan (ACF). Khác với các phương pháp tiếp cận chuỗi thời gian thông thường vốn bỏ qua tính phân mảnh của hạ tầng, AeroDelay thực hiện audit hàm ACF dựa trên hai khía cạnh độc lập: lưu lượng chịu tải tổng hợp của cảng hàng không (*Airport Load*) và chuỗi thời gian trễ cất cánh tích lũy theo giờ (*Delay Propagation*).

Hệ số tự tương quan tại độ trễ k (ký hiệu là ρ_k) của chuỗi dữ liệu Y_t được định nghĩa bằng công thức toán học:

$$\rho_k = \frac{\sum_{t=1}^{T-k} (Y_t - \bar{Y})(Y_{t+k} - \bar{Y})}{\sum_{t=1}^T (Y_t - \bar{Y})^2} \quad (1)$$

Trong đó T là tổng số mốc thời gian quan sát theo giờ, và $\bar{Y}$ là giá trị trung bình toàn cục của chuỗi dữ liệu mục tiêu. Kết quả trực quan hóa hàm ACF thực nghiệm từ dữ liệu trên ba cảng hàng không trọng điểm (SGN, HAN, DAD) được thể hiện chi tiết tại Hình 7 và Hình 8.




Fig. 7. Đồ thị ACF lưu lượng khai thác theo giờ trên các cảng hàng không




Fig. 8. Đồ thị ACF số phút trễ cất cánh trung bình theo giờ

Dựa trên kết quả thực nghiệm thu được từ hệ thống đồ thị, nhóm nghiên cứu rút ra hai phát hiện lý giải cho logic thiết kế các nhóm đặc trưng ở phần sau:

- 1) **Tính chu kỳ trong vận hành hạ tầng hàng không:** Như quan sát tại Hình 7, biểu đồ ACF của tổng lưu lượng chuyến bay (cất cánh kết hợp hạ cánh) trên cả ba sân bay đều xuất hiện các đỉnh tương quan cục bộ nhô cao vượt trội qua dải tin cậy 95% tại đúng các mốc độ trễ tuần hoàn $k = 24$, $k = 48$, và $k = 72$ giờ. Hiện tượng này chứng minh tính lặp lại tuyệt đối của áp lực tải trọng không lưu theo chu kỳ ngày-đêm. Đây chính là logic để hệ thống AeroDelay xây dựng các biến vĩ mô tiên nghiệm bám sát khung giờ cao điểm của đài ATC như *Hour_of_Day* hay *Is_Peak_Hour*.
- 2) **Quán tính lan truyền trễ chuyển ngắn hạn (*Short-term Delay Momentum*):** Tại Hình 8, đồ thị ACF của số phút trễ trung bình cho thấy hệ số tương quan đạt giá trị cực đại tại các mốc độ trễ ngắn đầu tiên ($k = 1, 2, 3$) và suy giảm dần theo dạng hàm mũ (*exponential decay*). Xu hướng này cho thấy bản chất của "hiện tượng tắc nghẽn tĩnh": khi một đầu sân bay bị tắc nghẽn hoặc quá tải sản phẩm tại mốc t , áp lực điều phối không lưu sẽ dội ngược và duy trì một hiệu ứng trễ chuyển kéo dài liên tục sang các khung giờ $t + 1$ và $t + 2$ kế tiếp.

Việc phân tích tường minh hàm ACF giúp AeroDelay xác định được hệ số tương quan dương kéo dài trong cửa sổ 3 giờ liền trước chính là cơ sở thực nghiệm quan trọng lý giải cho việc thiết kế tập đặc trưng trễ chặng trước (*Lag Features*) cho các mô hình thực nghiệm ở phần sau, giúp các mô hình nắm bắt được 2 điểm mấu chốt: quán tính tắc nghẽn ngắn hạn và chu kỳ chịu tải dài hạn của toàn bộ mạng lưới không lưu.

E. Các nhóm đặc trưng chính trong Gold Dataset

Các nhóm đặc trưng chính trong Gold dataset được tóm tắt trong Bảng XIII. Các nhóm đặc trưng chính được xây dựng dựa trên sự kết hợp giữa yếu tố lịch trình, hạ tầng và môi

trường vận hành. Cụ thể, mô hình khai thác tính chu kỳ của lịch bay kết hợp với đặc điểm kỹ thuật của tàu bay để phân định năng lực khai thác riêng biệt. Điểm cốt lõi nằm ở khả năng mô hình hóa hiệu ứng dây chuyền, nơi lịch sử chậm trễ và thời gian xoay vòng của cùng một tàu bay được theo dõi chặt chẽ để dự báo các tác động lan truyền. Bên cạnh đó, áp lực từ mật độ tại sân bay (bao gồm cả điểm đi và điểm đến), kết hợp với các dữ liệu thời tiết vận hành, đóng vai trò như các biến số môi trường quan trọng giúp định lượng chính xác rủi ro trễ chuyển trong toàn bộ mạng bay.

F. Kiểm soát Data Leakage

Gold dataset được kiểm soát chặt chẽ để đảm bảo tính hợp lệ của benchmark. Pipeline không sử dụng *Actual_Time*, *Departure_Delay* và các trường có nguy cơ rò rỉ có tính liên kết như *Matched_Actual_Tail* hoặc *Runway_Swap_Event* làm dữ liệu huấn luyện. Các lag feature chỉ sử dụng thông tin đã xảy ra trước *Scheduled_Time*, weather feature được join theo *Scheduled_Time*, và tất cả ngưỡng quan trọng đều dùng quy tắc nghiệp vụ thay vì học từ toàn bộ dữ liệu.

Kết quả audit cho thấy không phát hiện vi phạm leakage trên 74 723 bản ghi chuyến bay departure.

G. Ý nghĩa của tập dữ liệu tầng Gold

Bộ dữ liệu tầng Gold là sản phẩm cốt lõi của AeroDelay. Đây không chỉ là bộ dữ liệu đầu vào cho mô hình mà còn là một benchmark dataset có khả năng tái lập cho các nghiên cứu sau này về vận hành hàng không tại Việt Nam. Nhờ kiến trúc Bronze–Silver–Gold cùng hệ thống audit đầy đủ, mọi bản ghi trong Gold đều có thể truy vết ngược về nguồn gốc, quyết định xử lý và logic feature engineering, đảm bảo tính minh bạch và độ tin cậy cao.

IV. THIẾT KẾ THỰC NGHIỆM

Mục tiêu chính của phần modeling trong AeroDelay không phải là tìm ra mô hình dự báo trễ chuyển dây chuyền tốt nhất, mà là kiểm chứng chất lượng và sức mạnh dự đoán của bộ dữ liệu tầng Gold. Thực nghiệm được thiết kế đơn giản, có kiểm soát nghiêm ngặt data leakage và dễ tái lập.

A. Dữ liệu và biến mục tiêu

Tập dữ liệu sử dụng cho modeling là tập dữ liệu các chuyến bay departure tổng hợp từ cả 3 sân bay: HAN, DAD, SGN tại tầng Gold. Tổng số bản ghi departure là 77 758, trong đó tập chuyến bay thương mại chở khách dùng cho huấn luyện và đánh giá gồm 72 375 bản ghi. Phạm vi thời gian kéo dài từ 15/12/2025 18:00 đến 16/03/2026 23:40.

Biến mục tiêu chính là *Departure_Delay_Reg_Target*, được tính bằng chênh lệch giữa *Actual_Time* và *Scheduled_Time*, sau đó rút gọn trong khoảng $[-60, 720]$ phút. Trên tập chuyến bay thương mại chở khách, mục tiêu có mean 34.15 phút, median 23 phút và p95 đạt 113 phút.

B. Chiến lược chia train/test

Đồ án sử dụng chiến lược phân chia dựa trên khoảng thời gian nhằm mô phỏng bối cảnh dự báo thực tế:

- Train: 15/12/2025 18:00 đến 28/02/2026 23:55, gồm 59 927 rows.
- Test: 01/03/2026 00:01 đến 16/03/2026 23:40, gồm 12 448 rows.

C. Các tập đặc trưng

Benchmark được tổ chức theo bốn nhóm tập đặc trưng tăng dần:

- *F0_base*: 24 đặc trưng.
- *F1_turnaround*: 28 đặc trưng.
- *F2_lag*: 38 đặc trưng.
- *F3_weather*: 50 đặc trưng.

D. Mô hình và baseline

Baseline được sử dụng là Dummy Median, tức mô hình luôn dự đoán median delay của tập huấn luyện. Các mô hình so sánh bao gồm Ridge, ExtraTrees, HistGradientBoosting, LightGBM, Quantile Regressor và Huber Quantile LightGBM.

E. Độ đo đánh giá

Để đánh giá mức độ hiệu quả của mô hình, 4 độ đo được sử dụng trong AeroDelay, bao gồm: Hệ số xác định (R^2), Sai số tuyệt đối trung bình (MAE), Sai số tuyệt đối trung vị (MedianAE), và Căn phương sai sai số trung bình (RMSE). Gọi y_i là số phút trễ cất cánh thực tế của chuyến bay thứ i , $\hat{y}_i$ là giá trị dự báo tương ứng từ mô hình, $\bar{y}$ là giá trị trung bình của toàn bộ tập dữ liệu thực tế, và N là tổng số mẫu trong tập kiểm thử.

- 1) Độ đo **MAE** đại diện cho mức độ sai lệch trung bình (tính bằng phút) giữa thời gian trễ dự báo và thời gian trễ thực tế trên mỗi chuyến bay. **MAE** càng thấp đồng nghĩa với việc độ tin cậy khi lập kế hoạch phân phối hàng hóa và cửa sổ dựa trên cấu hình dự báo càng cao:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (2)$$

- 2) Hệ số **R^2** đo lường tỷ lệ phần trăm sự biến thiên của số phút trễ chuyến thực tế được giải thích bởi các đặc trưng tiên nghiệm có trong mô hình. Một chỉ số **R^2** dương và ổn định cho thấy mô hình đã học được chuỗi xoay vòng tàu bay và khí tượng thay vì dự báo ngẫu nhiên:

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (3)$$

- 3) Bằng cách lấy giá trị trung vị của mảng sai số tuyệt đối, **MedianAE** phản ánh năng lực dự báo của mô hình trên đại đa số các chuyến bay thường lệ mà không bị nhiễu bởi một vài outliers trễ quá mức:

$$MedianAE = \text{median}(|y_1 - \hat{y}_1|, |y_2 - \hat{y}_2|, \dots, |y_N - \hat{y}_N|) \quad (4)$$

TABLE XIII
CÁC NHÓM ĐẶC TRƯNG CHÍNH TRONG GOLD DATASET

Nhóm đặc trưng	Feature tiêu biểu	Ý nghĩa
Lịch bay và thời gian	<i>Scheduled_Hour</i> , <i>Scheduled_DayOfWeek</i> , <i>Time_of_Day</i> , <i>Peak_Hour_Indicator</i>	Mô tả chu kỳ khai thác, ngày trong tuần, cuối tuần và các khung giờ cao điểm.
Tàu bay và loại chuyến	<i>Aircraft_Type</i> , <i>Category</i> , <i>Airline_Type</i> , <i>Is_Wide_Body</i> , <i>Is_First_Flight</i>	Phân biệt đặc điểm vận hành của từng loại tàu bay, hãng bay và loại hình khai thác.
Xoay vòng tàu bay và chậm trễ lan truyền	<i>Standard_Turnaround</i> , <i>Turnaround_Deficit_Min</i> , <i>Prev_Delay_Tail</i> , <i>Rolling_Delay_Tail</i>	Mô hình hóa cơ chế trễ dây chuyền thông qua thời gian xoay vòng và lịch sử trễ của cùng tàu bay.
Tải sân bay và tắc nghẽn	<i>Airport_Load_Factor</i> , <i>Flights_Last_Hour</i> , <i>Is_Airport_Congested</i> , <i>Taxi_Out_Congestion</i>	Phản ánh áp lực hạ tầng, mật độ khai thác và trạng thái tắc nghẽn tại sân bay.
Mạng lưới bay và trạm bay trước	<i>Destination_Congestion_Risk</i> , <i>Previous_Station_Disruption</i> , <i>A_CDM_TOBT_Deficit</i>	Mô tả ảnh hưởng từ sân bay đích, chặng trước và áp lực vận hành mặt đất.
Thời tiết vận hành	<i>Runway_Wet_Risk</i> , <i>Is_Crosswind</i> , <i>Is_Fog</i> , <i>Weather_Risk_Score</i> , <i>Operational_Risk_Score</i>	Biểu diễn tác động của điều kiện khí tượng đến runway, năng lực khai thác và nguy cơ trễ.

- 4) Ngược lại với **MedianAE**, **RMSE** xử lý trực tiếp các sai số lớn bằng cách bình phương các khoảng chênh lệch trước khi lấy trung bình và căn bậc hai. Do đó, chỉ số **RMSE** có vai trò buộc các mô hình phải tối ưu hóa để thu hẹp khoảng cách tại các vùng phân phối trễ nặng:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (5)$$

F. Kết quả đánh giá thực nghiệm

Bảng XIV trình bày top 5 kết quả tốt nhất trên tập Test.

Kết quả benchmark cho thấy tập dữ liệu tại tầng Gold có tín hiệu dự đoán rõ ràng. Mô hình tốt nhất là LightGBM trên feature set *F3_weather*, đạt MAE 13.38 phút, MedianAE 7.46 phút, RMSE 28.41 phút và $R^2 = 0.241$.

So với baseline là Dummy Median với MAE 18.10 phút, mô hình tốt nhất cải thiện 26.1% MAE, tương ứng giảm 4.72 phút sai số trung bình.

- **MAE 13.38 phút:** Sai số trung bình ở mức hợp lý đối với bài toán dự báo delay hàng không.
- **MedianAE 7.46 phút:** Phần lớn dự đoán có sai số nhỏ, cho thấy mô hình hoạt động tốt với các trường hợp trễ phổ biến.
- **RMSE 28.41 phút:** RMSE cao hơn MAE cho thấy mô hình vẫn gặp khó khăn với các trường hợp delay cực trị ở đuôi phân phối.
- $R^2 = 0.241$: Mức giải thích phù hợp trong bối cảnh delay hàng không chịu ảnh hưởng của nhiều yếu tố ngoại sinh chưa được quan sát đầy đủ.

TABLE XV
SO SÁNH CÁC TẬP ĐẶC TRƯNG VỚI MÔ HÌNH LIGHTGBM

Tập đặc trưng	MAE	Cải thiện
F0_base	15.73	13.1%
F1_turnaround	15.10	16.6%
F2_lag	13.39	26.0%
F3_weather	13.38	26.1%

Kết quả trong Bảng XV cho thấy *F2_lag* mang lại bước cải thiện lớn nhất, chứng tỏ trễ dây chuyền là tín hiệu dự đoán mạnh. Các đặc trưng về khí tượng hàng không trong *F3_weather* bổ sung tín hiệu vận hành, nhưng không chi phối toàn bộ kết quả.

G. Kết quả đánh giá theo từng sân bay

Trên tập Test, MAE theo sân bay lần lượt là 8.93 phút tại DAD, 13.68 phút tại HAN và 14.68 phút tại SGN. SGN là sân bay khó dự báo nhất do có mật độ khai thác cao và tắc nghẽn trong vận hành thường xuyên hơn.

Nhìn chung, kết quả benchmark khẳng định tập dữ liệu tại tầng Gold có giá trị dự đoán thực tế và các đặc trưng dựa trên nghiệp vụ hàng không hoạt động hiệu quả. Đây là bằng chứng cho chất lượng pipeline, đồng thời tạo nền tảng tốt cho các nghiên cứu tiếp theo về trễ lan truyền tại Việt Nam.

V. MỞ RỘNG

Bên cạnh pipeline chính Bronze–Silver–Gold và benchmark mô hình, AeroDelay còn phát triển một số thành phần mở rộng nhằm tăng tính ứng dụng thực tế của tập dữ liệu tầng Gold.

A. Triển khai giao diện tương tác Streamlit

Web tương tác được xây dựng bằng Streamlit, cho phép người dùng tương tác trực tiếp với tập dữ liệu tại tầng Gold và mô hình đã huấn luyện. Các chức năng chính bao gồm:

- Dashboard tổng quan vận hành: số chuyến, tỷ lệ trễ, lưu lượng theo giờ, phân bố theo sân bay và hãng bay.
- Mô phỏng trễ dây chuyền theo logic trong tài liệu A-CDM.
- Công cụ dự đoán trễ chuyến theo dữ liệu người dùng nhập vào.
- Góc nhìn hành khách, đưa ra khuyến nghị thời gian đến sân bay và mật độ tải của sân bay được thể hiện trực quan trên bản đồ dựa trên rủi ro trễ của từng sân bay.

B. Gán nhãn nguyên nhân trễ bằng LLM

Hệ thống sử dụng LLM thông qua Ollama để tự động gán nhãn nguyên nhân trễ chuyến cho các chuyến bay trễ từ 15 phút trở lên theo tài liệu về IATA delay code chuẩn của Hiệp

TABLE XIV
TOP 5 KẾT QUẢ BENCHMARK TRÊN TẬP TEST

Hạng	Tập đặc trưng tốt nhất	Mô hình	MAE	MedianAE	RMSE	R^2
1	F3_weather	LightGBM	13.38	7.46	28.41	0.241
2	F2_lag	LightGBM	13.39	7.51	28.45	0.239
3	F3_weather	Huber Quantile LGBM	13.44	7.48	28.52	0.236
4	F2_lag	Huber Quantile LGBM	13.46	7.55	28.58	0.233
5	F3_weather	Quantile Regressor	13.55	7.62	28.71	0.228
–	Baseline	Dummy Median	18.10	9.00	32.85	–

hội Vận tải Hàng không Quốc tế. LLM nhận đầu vào là các đặc trưng vận hành từ tập dữ liệu Gold, bao gồm turnaround buffer, airport load, weather risk và propagation delay, sau đó trả về JSON chứa *Delay_Code* cùng phần giải thích ngắn gọn. Vai trò của LLM không phải là tham gia huấn luyện để dự đoán số phút trễ, mà có vai trò giám định để tự động hóa quy trình phân tích nguyên nhân gốc rễ và làm giàu dữ liệu ngữ nghĩa cho tầng Gold. Giá trị của việc này được thể hiện rõ trên giao diện Streamlit, khi hệ thống hiển thị ngay lập tức chẩn đoán trễ, giúp điều phối viên hiểu rõ tại sao chuyến bay bị trễ để kịp thời đưa ra quyết định giải tỏa hạ tầng.

Kết quả gán nhãn được lưu trong file *master_departure_features_gold_annotated.csv*. Kết quả đồng thuận giữa LLM và con người trên 100 mẫu cho thấy độ chính xác hiện tại khoảng 26%, cho thấy LLM chỉ đóng vai trò hỗ trợ diễn giải và chưa thể thay thế nhãn ground truth.

C. Điều phối pipeline qua Dagster

Toàn bộ quy trình được đóng gói và điều phối bằng Dagster, với các asset tương ứng theo từng tầng dữ liệu. Pipeline được chia thành ba nhiệm vụ chính:

- **Nhiệm vụ 1:** Bronze → Audit.
- **Nhiệm vụ 2:** Cào dữ liệu bổ sung và EDA.
- **Nhiệm vụ 3:** Đặc trưng tầng Gold → Gán nhãn LLM → huấn luyện mô hình.

Cách tổ chức này đảm bảo tính tái lập, có checkpoint audit và dễ dàng quản lý quy trình từ đầu đến cuối.

VI. THẢO LUẬN

Tuy nhiên, đồ án vẫn tồn tại một số hạn chế đáng kể. Phạm vi dữ liệu hiện chỉ tập trung vào ba sân bay lớn gồm SGN, HAN và DAD, do đó chưa đại diện đầy đủ cho toàn bộ mạng bay Việt Nam. Bên cạnh đó, khoảng thời gian dữ liệu từ 15/12/2025 đến 16/03/2026 còn tương đối ngắn, chưa phản ánh đầy đủ tính mùa vụ và các biến động dài hạn trong vận hành hàng không.

Nguồn dữ liệu chủ yếu được thu thập từ FlightRadar24 và các nguồn công khai, nên còn thiếu nhiều thông tin quan trọng từ hệ thống nội bộ như gate/stand assignment, ground handling, crew rotation, maintenance log, bãi đỗ giới hạn do ATC sắp xếp và lý do delay chính thức. Đây là những yếu tố có thể ảnh hưởng trực tiếp đến trễ chuyến nhưng chưa được quan sát đầy đủ trong bộ dữ liệu hiện tại.

Thành phần diễn giải nguyên nhân trễ bằng LLM vẫn còn hạn chế. Hệ thống gán nhãn LLM hiện chỉ đạt độ chính xác

khoảng 26% khi kiểm chứng. Thành phần này có thể hỗ trợ diễn giải tương đối tốt các nhóm delay liên quan đến thời tiết, tắc nghẽn và xoay vòng tàu bay, nhưng chưa mô hình hóa đầy đủ các nguyên nhân như ground handling, baggage, technical issue và crew delay. Vì vậy, gán nhãn bằng LLM chỉ nên được xem là lớp hỗ trợ giải thích, chưa thể thay thế nhãn ground truth chính thức.

Ngoài ra, đặc trưng khí tượng hiện được xây dựng từ dữ liệu thời tiết theo giờ, chưa tích hợp dự báo và cấu hình đường băng thực tế. Entity resolution và imputation cho arrival-departure vẫn mang tính suy luận, nên có thể phát sinh sai lệch trong một số trường hợp đặc biệt. Mô hình benchmark đạt $R^2 = 0.241$, cho thấy vẫn còn nhiều yếu tố ngoại sinh chưa được quan sát trong dữ liệu.

Mặc dù còn những hạn chế trên, AeroDelay đã tạo ra một pipeline dữ liệu minh bạch, có audit và tái lập cao trong khả năng của các nguồn dữ liệu thực hiện thu thập. Tập dữ liệu tầng Gold không chỉ phục vụ benchmark mô hình mà còn là nền tảng vững chắc để mở rộng nghiên cứu về trễ dây chuyền tại Việt Nam, đặc biệt khi kết hợp thêm dữ liệu nội bộ từ hãng bay và cảng hàng không trong tương lai.

VII. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Đồ án AeroDelay đã xây dựng thành công một pipeline dữ liệu theo kiến trúc Bronze–Silver–Gold cho bài toán phân tích trễ dây chuyền chuyển bay tại ba sân bay lớn SGN, HAN và DAD. Bộ dữ liệu tại tầng Gold được tạo ra với 77 758 bản ghi departure, trong đó có 72 375 bản ghi chuyển bay thương mại chở khách, kèm theo các đặc trưng mang tính nghiệp vụ về xoay vòng tàu bay, khả năng trễ lan truyền, tải sân bay và rủi ro về khí tượng hàng không. Benchmark mô hình tốt nhất đạt MAE 13.38 phút, cải thiện 26.1% so với Dummy Median baseline. Kết quả này khẳng định tập dữ liệu cuối cùng chứa tín hiệu dự đoán thực tế và các đặc trưng được thiết kế có giá trị vận hành. Ngoài pipeline chính, đồ án còn phát triển các thành phần mở rộng như Dashboard có giao diện trực quan trên Streamlit, gán nhãn lý do trễ theo chuẩn IATA code bằng LLM và hệ thống điều phối pipeline qua Dagster, cho thấy khả năng khai thác đa dạng của tập dữ liệu. Tóm lại, giá trị cốt lõi của AeroDelay nằm ở việc xây dựng một nền tảng dữ liệu sạch cho nghiên cứu khả năng trễ dây chuyền trong bối cảnh hàng không Việt Nam.

Trong tương lai, AeroDelay có thể được mở rộng theo nhiều hướng nhằm tăng độ bao phủ và khả năng ứng dụng thực tế. Trước hết, phạm vi dữ liệu nên được mở rộng sang nhiều sân

bay hơn và kéo dài thời gian quan sát để phản ánh đầy đủ tính mùa vụ trong một năm. Bên cạnh đó, việc tích hợp dữ liệu nội bộ của sân bay và hãng hàng không như gate/stand assignment, ground handling, crew rotation, maintenance log và ATC slot restriction sẽ giúp mô hình hóa chính xác hơn các nguyên nhân trễ. Thành phần gán nhãn nguyên nhân trễ cũng cần được cải thiện thông qua bộ nhãn IATA delay code chất lượng cao kết hợp đánh giá đồng thuận giữa con người và LLM. Về mô hình, có thể thử nghiệm các hướng sequence-based hoặc graph-based để nắm bắt tốt hơn tính lan truyền trễ trong mạng bay. Cuối cùng, hệ thống có thể được nâng cấp thành một MLOps pipeline hoàn chỉnh với giám sát, phát hiện dữ liệu trôi dạt và production dashboard cho các bên liên quan. Với các hướng phát triển này, AeroDelay có tiềm năng trở thành nền tảng dữ liệu tham chiếu cho các nghiên cứu và ứng dụng thực tế về vận hành hàng không tại Việt Nam.

REFERENCES

- [1] A. Sternberg, J. Soares, D. Carvalho, and E. Ogasawara, “A Review on Flight Delay Prediction,” <https://arxiv.org/abs/1703.06118>, 2017.
- [2] R. K. Jha, S. B. Jha, V. Pandey, and R. F. Babiceanu, “Flight Delay Prediction using Hybrid Machine Learning Approach: A Case Study of Major Airlines in the United States,” <https://arxiv.org/abs/2409.00607>, 2024.
- [3] P. Fleurquin, J. J. Ramasco, and V. M. Eguíluz, “Characterization of delay propagation in the US air transportation network,” <https://arxiv.org/abs/1304.2528>, 2013.
- [4] L. Xu et al., “Aeolus: A Multi-structural Flight Delay Dataset,” <https://arxiv.org/abs/2510.26616>, 2025.
- [5] Zhou et al., “Two-stage Model for Flight Delay Prediction with Propagation Modeling,” 2022.
- [6] U.S. Bureau of Transportation Statistics, “Airline On-Time Performance Data / TranStats,” [Online]. Available: <https://www.transtats.bts.gov/>
- [7] Flightradar24, “How Flightradar24 Works,” [Online]. Available: <https://www.flightradar24.com/how-it-works>
- [8] Open-Meteo, “Historical Weather API Documentation,” [Online]. Available: <https://open-meteo.com/en/docs/historical-weather-api>
- [9] International Air Transport Association (IATA), “IATA Delay Codes (AHM 730),” Standardized Delay Reason Codes.
- [10] EUROCONTROL, “All-causes Delay and Cancellations to Air Transport in Europe,” 2019.
- [11] EUROCONTROL, “EUROCONTROL Specification for Airport Collaborative Decision Making (A-CDM),” Edition 1.0, Jan. 30, 2025. [Online]. Available: <https://www.eurocontrol.int/concept/airport-collaborative-decision-making>

APPENDIX A

DATASHEET FOR AERODELAY GOLD DATASET

Phụ lục này trình bày datasheet cho bộ dữ liệu Gold của AeroDelay, được soạn theo khung khuyến nghị của Gebru et al. trong *Datasheets for Datasets*. Mục tiêu là cung cấp thông tin toàn diện và minh bạch về nguồn gốc, quy trình xây dựng, thành phần, mục đích sử dụng, giới hạn và trách nhiệm bảo trì của dataset. Data codebook chi tiết được cung cấp riêng trong file *CODEBOOK_AERODELAY_GOLD.xlsx*, mô tả tên cột, kiểu dữ liệu, ý nghĩa, nguồn gốc và trạng thái sử dụng trong mô hình.

A. Thông tin tổng quan dataset

TABLE XVI
THÔNG TIN TỔNG QUAN VỀ AERODELAY GOLD DATASET

Thuộc tính	Giá trị
Tên dataset	DS108-AeroDelay Gold
Phiên bản	v1.0
Mục tiêu chính	Bộ dữ liệu chuẩn hóa, có audit và có tín hiệu dự đoán cho bài toán trễ dây chuyền chuyển bay
Đơn vị quan sát	Một chuyến bay departure
Phạm vi sân bay	Tân Sơn Nhất (SGN), Nội Bài (HAN), Đà Nẵng (DAD)
Thời gian dữ liệu	15/12/2025 18:00:00–16/03/2026 23:40:00
Bản ghi tầng Silver	151 929 bản ghi arrival và departure
Bản ghi tầng Gold	148 519 bản ghi
Tổng bản ghi chuyển bay	77 758 dòng, khoảng 78 cột
Departure tầng Gold	
Bản ghi chuyển bay chờ khách tầng Gold	72 375 dòng
Nguồn chuyển bay	FlightRadar24 và dữ liệu bổ sung từ Cảng hàng không Đà Nẵng
Nguồn thời tiết	Open-Meteo Historical Weather API
Target chính	<i>Departure_Delay_Reg_Target</i> , clip trong khoảng $[-60, 720]$ phút
Recommended split	Time-based split
Train/Test	59 927 / 12 448 rows
Bản quyền	Học thuật nội bộ đồ án; khi sử dụng công khai cần tuân thủ điều khoản của FlightRadar24 và Open-Meteo

B. Motivation

Dataset AeroDelay Gold được xây dựng nhằm lấp khoảng trống về dữ liệu chuẩn hóa và pipeline có khả năng tái lập cho nghiên cứu trễ dây chuyền chuyển bay tại Việt Nam. Dataset tập trung xử lý các vấn đề phổ biến của dữ liệu hàng không thực tế như khác biệt semantics thời gian, missing runway, thiếu liên kết arrival–departure và duplicate. Bên cạnh đó, dataset xây dựng các đặc trưng mang ý nghĩa vận hành như turnaround buffer, delay propagation, airport load và weather operational risk, đồng thời kiểm chứng xem Gold dataset có chứa tín hiệu dự đoán thực tế hay không. Dataset được thực hiện bởi nhóm 18 thuộc lớp học phần DS108.Q21, Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, không có tài trợ bên ngoài và không chứa thông tin cá nhân của hành khách.

C. Composition

Mỗi bản ghi trong Gold dataset đại diện cho một chuyến bay departure tại SGN, HAN hoặc DAD. Mỗi bản ghi bao gồm

các nhóm thông tin chính: flight identity, time fields, aircraft and operation, turnaround and propagation, airport congestion, network and A-CDM, weather operational features, audit flags và quality flags. Một số cột tiêu biểu gồm *Flight_No*, *Airline*, *Origin*, *Destination*, *Scheduled_Time*, *Actual_Time*, *Aircraft_Type*, *Tail_Number*, *Turnaround_Deficit_Min*, *Rolling_Departure_Delay_Tail*, *Airport_Load_Factor*, *Runway_Wet_Risk*, *Weather_Delay_Risk_Score*, *Is_Imputed_Link* và *Data_Completeness*. Biện mục tiêu chính là *Departure_Delay_Reg_Target*, biểu diễn trễ theo phút. Tập dữ liệu tập trung vào chuyến bay chở khách và chỉ bao quát phần lớn mạng bay Việt Nam.

D. Collection Process

Dữ liệu chuyến bay được thu thập chủ yếu từ FlightRadar24 bằng hệ thống cào dữ liệu chuyên biệt, bao gồm cào dữ liệu trong quá khứ, crawler gần thời gian thực và cào bổ sung chuyến bay bị thiếu. Dữ liệu tại DAD được bổ sung thêm từ Cảng hàng không quốc tế Đà Nẵng. Dữ liệu thời tiết được lấy từ Open-Meteo Historical Weather API theo tần suất một giờ tại tọa độ của ba sân bay. Quá trình thu thập không bao gồm thông tin cá nhân hành khách.

E. Preprocessing, Cleaning, and Labeling

Toàn bộ quy trình được tổ chức theo kiến trúc Bronze–Silver–Gold với kiểm soát data leakage nghiêm ngặt. Tầng Bronze lưu dữ liệu thô gần nguồn. Tầng Silver chuẩn hóa schema, chuẩn hóa ngữ nghĩa thời gian, xử lý missing runway, deduplication, entity resolution giữa arrival–departure và audit chất lượng. Tầng Gold thực hiện feature engineering cho turnaround, lag delay, airport load và weather features, đồng thời thực hiện nội suy có kiểm soát và gán cờ audit. Ngoài ra, tập dữ liệu có phiên bản mở rộng với gán nhãn bằng LLM để gán nhãn nguyên nhân trễ theo IATA code, phục vụ giải thích nguyên nhân trễ của từng chuyến bay trễ trên 15 phút.

F. Uses

Tập dữ liệu được khuyến khích sử dụng cho phân tích và dự báo trễ cho các chuyến bay departure, nghiên cứu trễ dây chuyền và xoay vòng tàu bay, đánh giá quá trình kỹ thuật đặc trưng cho dữ liệu hàng không, cũng như phát triển dashboard tương tác và tạo nguyên mẫu hệ thống hỗ trợ vận hành. Tuy nhiên, tập dữ liệu không nên được sử dụng cho quyết định vận hành thời gian thực, điều phối slot/gate/crew, phân tích trách nhiệm pháp lý hoặc quy kết nguyên nhân cho hãng bay và sân bay. Nhãn được gán bởi LLM cũng không nên được xem là ground truth chính thức.

G. Distribution

Tập dữ liệu được tổ chức theo cấu trúc tầng Bronze/Silver/Gold trong thư mục lưu trữ đồ án. Khi phân phối, cần đi kèm file CSV tầng Gold chính, codebook chi tiết, datasheet này, các báo cáo audit và notebook tái lập kết quả thực nghiệm mô hình.

H. Maintenance

Dataset hiện do nhóm quản lý. Các phiên bản sau cần được báo cáo phiên bản rõ ràng, ví dụ v1.0, v1.1 hoặc v2.0. Mọi cập nhật cần chạy lại đầy đủ các bước audit về data leakage, feature extraction và thực nghiệm mô hình để đảm bảo tính nhất quán.

I. Audit và kiểm soát chất lượng

AeroDelay lưu trữ đầy đủ các báo cáo audit như temporal leakage, imputation, feature eligibility, runway handling, ... Kết quả thực nghiệm hiện tại với LightGBM và tập đặc trưng *F3_weather* đạt MAE 13.38 phút, cải thiện 26.1% so với baseline, khẳng định tập dữ liệu có tín hiệu dự đoán thực tế.

J. Known Limitations

Tập dữ liệu hiện giới hạn ở ba sân bay và khoảng ba tháng dữ liệu. Bộ dữ liệu chưa có các nguồn nội bộ như gate, ground handling, crew và maintenance. Gán nhãn lý do trễ chuyến bằng LLM chỉ mang tính hỗ trợ với độ chính xác khoảng 26%. Ngoài ra, dữ liệu khí tượng hàng không hiện ở mức theo giờ và chưa tích hợp dữ liệu dự báo.

K. Ethical and Responsible Use Notes

Tập dữ liệu không chứa thông tin định danh cá nhân. Khi sử dụng, cần tránh diễn giải theo hướng quy trách nhiệm pháp lý cho bất kỳ bên nào nếu chưa có dữ liệu chính thức. Tập dữ liệu chỉ nên được dùng cho mục đích học thuật và nghiên cứu.